

Modelo Probabilístico de Previsão de Resultados de Futebol na Liga Portuguesa

Francisca Mateus
uc2023212096@student.uc.pt

Faculdade de Ciências e Tecnologias da Universidade de Coimbra

Licenciatura em Inteligência Artificial e Ciência de Dados
Inteligência Artificial Probabilística

1 Introdução

1.1 Contexto

O futebol é um domínio caracterizado por uma elevada incerteza, onde o resultado final de um jogo depende de uma multiplicidade de fatores dinâmicos e estocásticos. Tradicionalmente, a previsão de resultados baseava-se na intuição de especialistas, contudo, a crescente disponibilidade de dados granulares permitiu a ascensão da modelagem probabilística. No contexto das apostas desportivas, a capacidade de quantificar a incerteza não é apenas uma vantagem teórica, mas uma necessidade prática, pois modelos que conseguem estimar probabilidades mais precisas do que as oferecidas pelas casas de apostas permitem identificar situações de “valor”, onde a utilidade esperada de uma decisão supera o risco associado.

1.2 Objetivos

O objetivo central deste trabalho é o desenvolvimento e a implementação de um sistema robusto de previsão probabilística para os resultados (Vitória, Empate, Derrota) de jogos da Liga Portuguesa de Futebol. Para tal, o projeto propõe-se a:

- Construir e comparar Redes Bayesianas baseadas tanto em conhecimento especializado como em algoritmos de aprendizagem de estrutura.
- Implementar classificadores probabilísticos e avaliar a sua calibração e incerteza através de técnicas como *Conformal Prediction*.
- Aplicar a Teoria de Utilidade para transformar previsões probabilísticas em decisões de aposta estratégicas, comparando o desempenho do modelo com as *odds* reais de mercado.

1.3 Dataset e Pré-processamento

Para este estudo, utilizou-se um conjunto de dados histórico da liga portuguesa contendo informações detalhadas sobre os confrontos, golos e as *odds* iniciais. O dataset original foi sujeito a um processo rigoroso de feature engineering para capturar a dinâmica competitiva das equipas, destacando-se variáveis como:

- **ht_form** e **at_form**: Indicadores de forma recente para as equipas da casa e visitante.
- **ht_attack** e **at_attack**: Métricas que quantificam o poder ofensivo.
- **odds_favorite**: Variável que sintetiza a expectativa do mercado.

O pré-processamento incluiu a limpeza de valores omissos e a discretização de variáveis contínuas, garantindo que os dados estivessem num formato adequado para a aprendizagem de parâmetros.

2 Redes Bayesianas

2.1 Construção da Estrutura

2.1.1 Configuração do Ambiente e Preparação de Dados

O fluxo de trabalho iniciou-se com uma etapa de filtragem onde foram selecionadas as variáveis mais relevantes para a modelação probabilística. Designadamente, consideraram-se a forma recente das equipas (`ht_form`, `at_form`), o potencial ofensivo (`ht_attack`, `at_attack`), o histórico de confrontos diretos (`h2h_dominance`) e a tendência do mercado (`odds_favorite`), variáveis discretizadas. Complementarmente, realizou-se uma análise exploratória inicial, focada na distribuição percentual das classes do resultado final (H, D, A), de forma a compreender as tendências base do domínio.




Figure 1: Distribuição percentual dos resultados na Liga Portuguesa (H: Casa, D: Empate, A: Fora).

A análise da distribuição dos resultados, apresentada na Figura 1, revela uma clara predominância de vitórias das equipas visitadas (Home). Esta assimetria estatística é fundamental para a modelação probabilística, uma vez que as probabilidades *a priori* do nosso sistema devem refletir esta tendência natural do domínio antes de considerarmos as métricas específicas de performance de cada equipa.

2.1.2 Abordagem Baseada em Engenharia de Conhecimento

A primeira abordagem na modelação da Rede Bayesiana consistiu na técnica de *Knowledge Engineering*, onde a estrutura do Grafo Acíclico Dirigido(DAG) foi definida manualmente. O objetivo foi mapear as relações causais e as dependências lógicas que regem o domínio do futebol profissional, utilizando as variáveis discretizadas do *dataset*.

As ligações definidas no modelo manual podem ser agrupadas em quatro eixos lógicos:

- **Desempenho e Forma:** As variáveis de ataque (`ht_attack` e `at_attack`) foram ligadas às respetivas variáveis de forma (`ht_form` e `at_form`). A lógica reside no facto de que uma elevada capacidade ofensiva é o motor principal para a obtenção de pontos e, consequentemente, para a manutenção de uma forma positiva ao longo da época.
- **Determinantes das Odds:** Considerou-se que as casas de apostas (`odds_favorite`) baseiam as suas avaliações na forma recente das equipas e no histórico de confrontos diretos (`h2h_dominance`). Assim, estas três variáveis convergem para o nó das *odds*, refletindo como o mercado processa a informação histórica.

- **Influências Diretas no Resultado:** O desfecho do jogo (**result**) é influenciado diretamente pelo potencial ofensivo das equipas e pela dominância histórica entre elas. Estas ligações capturam a componente técnica e psicológica que define quem tem maior probabilidade de vencer o confronto.
- **Informação Latente do Mercado:** A ligação da variável **odds_favorite** ao **result** justifica-se pelo facto de as *odds* funcionarem como um agregador de informação latente que não está explicitamente no *dataset* (como lesões de última hora, castigos de jogadores-chave ou condições meteorológicas), mas que tem impacto direto no resultado final.




Figure 2: Estrutura da Rede Bayesiana definida via Engenharia de Conhecimento.

2.2 Aprendizagem Automática de Estrutura

Para complementar a abordagem baseada em conhecimento, implementou-se uma estratégia de aprendizagem de estrutura, puramente baseada nos dados. O objetivo desta etapa é identificar correlações e dependências estatísticas que podem não ser óbvias através da análise intuitiva do domínio.

2.2.1 Algoritmo Hill Climb Search e Métrica BIC

Utilizou-se o algoritmo **Hill Climb Search**, uma técnica de procura heurística que explora o espaço de todos os Grafos Acíclicos Dirigidos possíveis. O algoritmo opera realizando operações locais e avaliando cada mudança através de uma função de pontuação.

A função de pontuação escolhida foi o **Bayesian Information Criterion (BIC)**. A métrica BIC é particularmente adequada para este problema pois equilibra dois fatores fundamentais:

1. **Verosimilhança (Likelihood):** Quão bem a estrutura explica os dados observados.
2. **Penalização de Complexidade:** O BIC penaliza estruturas com excesso de parâmetros, prevenindo o *overfitting* e favorecendo modelos mais simples que generalizam melhor para novos jogos.

2.2.2 Análise da Estrutura Aprendida




Figure 3: Estrutura da Rede Bayesiana aprendida automaticamente através do algoritmo Hill Climb Search com score BIC.

2.2.3 Análise da Estrutura Aprendida e Comparação com o Modelo Manual

A análise comparativa entre o modelo manual e o modelo automático revela as nuances entre a causalidade teórica e a correlação estatística.

Validação Estatística de Pressupostos Manuais Observa-se que diversas arestas fundamentais foram mantidas na estrutura automática, o que valida estatisticamente as nossas hipóteses iniciais. As ligações **ht_attack** → **ht_form** e **at_attack** → **at_form** permanecem inalteradas, confirmando que a capacidade ofensiva é o motor primário da forma recente. Da mesma forma, as arestas que convergem para o desfecho final, nomeadamente **odds_favorite** → **result** e **h2h_dominance** → **result**, foram validadas pelo algoritmo. Isto demonstra que, independentemente da complexidade da rede, o histórico de confrontos e as probabilidades de mercado são os preditores mais robustos da performance real na Liga Portuguesa.

Divergências entre Causalidade e Correlação Estatística Contudo, o modelo automático introduziu arestas que, embora façam sentido estatístico para minimizar o *score* BIC, parecem desafiar a lógica empírica ou a causalidade temporal:

- **Inversão Causal (**ht_form** → **h2h_dominance**):** Enquanto que manualmente assumimos que o histórico (*h2h*) é um dado fixo, o algoritmo sugere que a forma atual “explica” o histórico. No plano estatístico, isto acontece porque equipas que estão em boa forma hoje tendem a ser equipas historicamente dominantes, criando uma dependência mútua que o algoritmo resolve com esta direção de aresta.
- **O Nó das Odds como Hub Informativo:** O algoritmo ligou **odds_favorite** diretamente a **at_attack** e **at_form**. Empiricamente, uma *odd* não causa o ataque de uma equipa, contudo, estatisticamente, a *odd* é um agregador de informação tão eficiente que ela se torna um excelente preditor de todas as outras variáveis de performance. O algoritmo prefere esta estrutura porque ela reduz a incerteza global da rede, utilizando a *odd* como uma variável “resumo” do estado das equipas.

Conclusão da Comparação Em suma, enquanto o modelo manual representa um mapa de **causalidade**, o modelo automático representa um mapa de **dependências estatísticas**. O facto de o algoritmo ter mantido as ligações core ao **result** reforça a confiança no sistema, enquanto as novas ligações em torno das *odds* confirmam que o mercado de apostas captura variáveis latentes que o nosso modelo manual tentava isolar individualmente.

2.3 Análise de Independências Condicionais (D-Separação)

A estrutura de uma Rede Bayesiana codifica um conjunto de afirmações de independência condicional. Para validar se estas propriedades se mantêm e compreender como a informação se propaga no modelo, utilizou-se o critério da **d-separação**.

2.3.1 Independências Locais e Globais

Modelo Manual: A análise das independências locais no modelo manual revela um padrão importante para o nó **result**:

$$(result \perp at_form, ht_form \mid at_attack, h2h_dominance, ht_attack, odds_favorite)$$

Isto indica que, uma vez conhecidos os pais diretos do resultado (ataque de ambas as equipas, histórico e as *odds*), a informação sobre a forma recente (**form**) torna-se redundante. Ou seja, a forma influencia o resultado apenas através do seu impacto no ataque e nas *odds*; se estes já estiverem quantificados, a forma não adiciona novo poder preditivo.

Modelo Automático: No modelo aprendido via *Hill Climb*, o algoritmo identificou independências globais que otimizam o *score* BIC. Um exemplo relevante é $(at_attack \perp result \mid h2h_dominance, odds_favorite)$, o que sugere que, estatisticamente, as *odds* e o histórico já capturam tanta informação que o ataque da equipa visitante deixa de ser uma variável independente necessária para explicar o desfecho.

2.3.2 Testes Práticos de D-Separação

Para validar a implementação, realizaram-se testes em estruturas fundamentais do grafo:

Estrutura em V (Colisor) e o efeito "Explaining Away" Analisou-se o caminho entre *ht_attack* e *at_attack*, que convergem no nó **result** ($ht_attack \rightarrow result \leftarrow at_attack$).

- **Sem observações:** As variáveis são **d-separadas**. O facto de uma equipa ter um bom ataque não nos diz nada sobre o ataque da outra equipa antes do jogo começar.
- **Observando result:** As variáveis tornam-se **dependentes**. Se soubermos que a equipa da casa perdeu, mas sabemos que teve um ataque excelente, isso "explica" (ou aumenta a probabilidade) de a equipa de fora ter tido um desempenho ainda superior. Este fenómeno é conhecido como *explaining away*.

Estrutura em Cascata (Chain) Analisou-se o fluxo informativo no caminho $ht_attack \rightarrow ht_form \rightarrow odds_favorite$.

- **Sem observações:** O caminho está **ativo**. O potencial de ataque influencia a forma, que por sua vez influencia as *odds*. Existe uma dependência indireta.
- **Observando ht_form:** O caminho fica **bloqueado** (d-separado). Ao conhecermos a forma atual da equipa, o conhecimento sobre o seu potencial de ataque teórico deixa de influenciar a nossa estimativa das *odds*, pois a forma já é o resultado concreto desse ataque.

Estrutura em Fork e as Odds como Hub: No modelo automático, analisou-se o caminho `at_attack` $\leftarrow$ `odds_favorite` $\rightarrow$ `result`, onde as *odds* assumem o papel de causa comum.

- **Sem observações:** O caminho está **ativo**. Existe uma dependência estatística entre a força do ataque visitante e o resultado, mediada pela percepção do mercado.
- **Observando `odds_favorite`:** O caminho fica **bloqueado** (d-separado). Ao conhecermos a cotação do mercado, a informação sobre o ataque do visitante torna-se redundante para prever o resultado. Isto valida a hipótese de que, nesta rede, as *odds* funcionam como um "hub informativo" que absorve as métricas técnicas.

Estrutura em Cascata e Atalhos Estatísticos: Avaliou-se a cadeia de dependência `ht_attack` $\rightarrow$ `ht_form` $\rightarrow$ `h2h_dominance`, que reflete uma inversão causal identificada pelo algoritmo.

- **Sem observações:** O caminho está **ativo**. O potencial de ataque influencia a forma, que por sua vez é usada pelo algoritmo para explicar a dominância histórica.
- **Observando `ht_form`:** O caminho fica **bloqueado**. A forma atual atua como um separador: uma vez conhecido o momento atual da equipa, a ligação entre o seu potencial ofensivo teórico e o histórico de confrontos é interrompida.

Este comportamento confirma que as redes implementadas respeitam os axiomas de grafos probabilísticos e que a inferência será realizada sobre caminhos de dependência válidos.

2.4 Aprendizagem de Parâmetros: MLE vs. Estimação Bayesiana

Após a definição da estrutura da Rede Bayesiana Manual, a etapa seguinte consistiu em aprender as Tabelas de Probabilidade Condicional (CPTs). Para este efeito, compararam-se duas abordagens distintas: a *Maximum Likelihood Estimation* (MLE) e a *Bayesian Estimation* (utilizando o *prior* BDeu).

A escolha do modelo manual para esta análise deve-se à sua elevada interpretabilidade causal, facilitando a validação das probabilidades aprendidas face ao conhecimento empírico do domínio.

2.4.1 Comparação Metodológica

Maximum Likelihood Estimation (MLE): Este método calcula as probabilidades baseando-se estritamente na frequência relativa dos dados. Como observado nos resultados, para a variável `ht_form`, quando o `ht_attack` é *weak*, a probabilidade de forma *excellent* é de exatamente 0.0000. Embora reflita fielmente o histórico, esta abordagem sofre do problema da probabilidade nula: se um evento nunca ocorreu no passado, o modelo assume que é impossível, o que pode bloquear processos de inferência futuros.

Estimação Bayesiana (BDeu): Para mitigar a rigidez do MLE, aplicou-se a Estimação Bayesiana com um *prior* uniforme equivalente (BDeu). Observando a mesma relação (`ht_attack weak` $\rightarrow$ `ht_form excellent`), o valor foi suavizado para 0.000440. Este processo de *smoothing* introduz "pseudo-contagens", garantindo que nenhuma combinação de eventos seja estritamente impossível, conferindo maior robustez ao modelo perante dados esparsos.

2.4.2 Análise das CPTs e Influência dos Dados

As tabelas aprendidas revelam como o *dataset* da Liga Portuguesa molda o comportamento do modelo:

- **Impacto do Ataque na Forma:** As CPTs demonstram uma correlação robusta. Por exemplo, uma equipa com `ht_attack strong` tem uma probabilidade de 49.8% de apresentar forma *excellent*. Inversamente, um ataque *weak* resulta em forma *poor* em 50.4% dos casos.
- **Configuração das Odds:** A variável `odds_favorite` atua como um agregador. Quando a equipa da casa é historicamente dominante e está em forma *excellent*, a probabilidade de as *odds* a apontarem como favorita é de 99.7%.

- **Determinismo do Resultado:** No nó `result`, observa-se que em cenários de total favoritismo (Ataque Forte + Histórico Favorável + *Odds* em *Home*), a probabilidade de vitória da casa (H) atinge os 82.7%. Contudo, o modelo preserva uma margem de incerteza para o empate (D) e derrota (A), refletindo a imprevisibilidade inerente ao desporto.

Conclusão da Aprendizagem Embora os valores centrais de ambas as abordagens sejam muito próximos para categorias com muitos dados, a **Estimação Bayesiana** revelou-se superior para a operacionalização do modelo, ao evitar o determinismo excessivo do MLE em casos raros.

2.5 Realização de Inferências Probabilísticas

A grande vantagem de uma Rede Bayesiana sobre classificadores tradicionais é a sua capacidade de realizar inferências em qualquer direção do grafo. Nesta secção, demonstramos a utilização do modelo para responder a cinco questões críticas, utilizando o algoritmo de eliminação de variáveis para calcular as distribuições *a posteriori*.

2.5.1 Cenários de Previsão e Diagnóstico

1. Previsão em Cenário de Superioridade: Questionou-se o modelo sobre a probabilidade de resultado dado que a equipa da casa apresenta forma *excellent*, ataque *strong* e um histórico *home_dominant*.

- **Resultado:** $P(H) = 78.5\%$, $P(D) = 14.3\%$, $P(A) = 7.2\%$.
- **Análise:** O modelo demonstra uma elevada confiança na vitória da casa sob estas condições, alinhando-se com a lógica desportiva onde a combinação de forma e superioridade técnica é determinante.

2. Inferência Diagnóstica (Causa dado o Efeito): Analisou-se um cenário onde a equipa da casa estava em má forma (*poor*) mas conseguiu vencer o jogo (H). Qual seria o estado provável da equipa visitante?

- **Resultado:** $P(at_form \in \{poor, below\ avg\}) \approx 53\%$.
- **Análise:** Perante uma vitória inesperada de uma equipa em má forma, o modelo infere que existe uma probabilidade superior a 50% de a equipa adversária também estar a atravessar um momento negativo, o que "ajuda a explicar" o desfecho observado.

3. Comportamento do Mercado face ao Equilíbrio: Num cenário de equilíbrio absoluto (ataques *average* e histórico *balanced*), para onde pendem as *odds*?

- **Resultado:** $P(odds_favorite = home) = 69.02\%$.
- **Análise:** Mesmo perante o equilíbrio técnico, as casas de apostas mantêm um forte favoritismo para o visitado. Isto reflete o peso estatístico do "fator casa" na Liga Portuguesa, que o modelo aprendeu a incorporar nas suas previsões.

2.5.2 Inter-causalidade e Conflito de Indicadores

4. Atualização de Percepção por Resultado: Avaliou-se a percepção do ataque visitante dado um ataque da casa *strong*, antes e depois de saber que o jogo empatou (D).

- **Sem saber o resultado:** $P(at_attack = above\ avg) = 19.27\%$.
- **Sabendo o Empate (D):** $P(at_attack = above\ avg) = 24.90\%$.
- **Análise:** O conhecimento do empate força o modelo a "ajustar" a sua percepção sobre a equipa de fora. Se a equipa da casa era forte e o jogo empatou, a probabilidade de a equipa visitante também ter um ataque acima da média sobe quase 6%, demonstrando o raciocínio inter-causal da rede.

5. Conflito entre Mercado e Histórico: Se as *odds* favorecem a equipa de fora (*away*), qual a probabilidade de o histórico ser dominado pela equipa da casa?

- **Resultado:** $P(h2h_dominance = home_dominant) = 1.39\%$.
- **Análise:** O modelo identifica um conflito extremo. Se o mercado ignora o fator casa para dar favoritismo ao visitante, a probabilidade de existir uma dominância histórica da casa torna-se quase nula. Isto indica que o modelo considera as *odds* como um indicador muito mais atualizado do que o histórico de longo prazo.

3 Classificação Probabilística e Incerteza

Nesta fase, o objetivo é transitar de um modelo baseado em grafos para classificadores probabilísticos que operam em espaços contínuos. O foco incide na capacidade de prever o desfecho (H, D, A) e, simultaneamente, quantificar a confiança do modelo nessas previsões.

3.1 Preparação e Pré-processamento de Dados

Antes da fase de modelação, os dados foram submetidos a um pipeline de preparação para garantir a validade estatística dos resultados.

3.1.1 Limpeza e Seleção de Atributos

Para evitar o fenómeno de *Data Leakage*, foram removidas variáveis que não estariam disponíveis no momento da previsão ou que codificam diretamente o resultado, designadamente os golos marcados (**hg**, **ag**) e identificadores temporais ou de equipa (**date**, **ht**, **at**).

Após esta limpeza, procedeu-se à separação das características (*features*) em dois grupos:

- **Variáveis Contínuas (18):** Incluem métricas de performance agregada (**form_points**, **goals_scored**) e as *odds* de mercado, que representam o consenso probabilístico externo.
- **Variáveis Discretas (7):** Categorias resultantes da discretização prévia, como o nível de ataque e dominância histórica.

Para os modelos de classificação nesta secção, optou-se por utilizar o conjunto de variáveis contínuas, por preservarem maior granularidade de informação.

3.1.2 Divisão do Dataset (Train-Calibration-Test)

Ao contrário de uma divisão binária convencional, os dados foram repartidos em três conjuntos distintos, uma etapa essencial para a implementação futura de *Conformal Prediction*:

1. **Treino (60%):** Utilizado para a aprendizagem dos parâmetros do modelo.
2. **Calibração (20%):** Reservado exclusivamente para ajustar as probabilidades e definir os *scores* de incerteza sem enviesar o treino.
3. **Teste (20%):** Utilizado para a avaliação final e reporte das métricas de desempenho.

3.1.3 Normalização e Escalonamento

Dado que as variáveis apresentam amplitudes muito distintas, aplicou-se a técnica de **Standardization (Z-score normalization)**.

É crucial notar que o transformador (**StandardScaler**) foi ajustado (*fit*) apenas com os dados de treino. A média (μ) e o desvio padrão (σ) resultantes foram depois aplicados aos conjuntos de calibração e teste. Este procedimento garante que não existe contaminação de informação, assegurando que o modelo é avaliado como se estivesse perante dados genuinamente novos.

3.2 Treino e Avaliação de Classificadores

Foram testadas diversas arquiteturas para estabelecer uma *baseline* de desempenho, utilizando parâmetros padrão discutidos em ambiente letivo. Os resultados comparativos encontram-se na Tabela 1.

Modelo	Exatidão	Log Loss
Logistic Regression	0.5336	0.9546
Gradient Boosting	0.5318	0.9763
Random Forest	0.5192	0.9814
SVM (RBF)	0.5246	0.9950
Naive Bayes	0.4655	2.1232
Neural Network (MLP)	0.4593	2.0266

Table 1: Desempenho comparativo entre os modelos.

Análise do Desempenho Comparativo A análise comparativa do desempenho dos classificadores revela que a **Regressão Logística** e o **Gradient Boosting** são os modelos mais robustos, apresentando as maiores exatidões (aproximadamente 53%) e os menores valores de *Log Loss* (0.9546 e 0.9763, respetivamente). Estes resultados sugerem que modelos lineares e de *ensemble* conseguem capturar de forma mais eficaz os padrões estatísticos da Liga Portuguesa, mantendo uma incerteza controlada.

Em contraste, o **Naive Bayes** apresenta o desempenho mais crítico em termos de probabilidade: embora a sua exatidão não seja a mais baixa, o seu elevado *Log Loss* (2.1232) indica uma calibração deficiente, onde o modelo atribui níveis de confiança excessivamente altos a previsões que acabam por se revelar incorretas. A proximidade dos resultados de exatidão entre os três primeiros modelos indica que o limite preditivo para este *dataset* ronda os 53%, refletindo a elevada imprevisibilidade inerente ao desfecho de jogos de futebol.




Figure 4: Comparação da densidade de probabilidade atribuída pelos diversos classificadores para cada desfecho possível. Cada gráfico sobrepõe o comportamento dos modelos testados para um resultado específico.

Análise das Distribuições de Probabilidade por Classe A Figura 4 oferece uma visão detalhada sobre a "certeza" de cada classificador para os três desfechos do jogo. Ao comparar as distribuições, emergem padrões distintos:

- **Vitória em Casa (H):** Na Figura 4c, observa-se que a maioria dos modelos (especialmente a Regressão Logística e SVM) apresenta uma cauda mais longa para a direita. Isto indica que os modelos encontram frequentemente evidência suficiente para atribuir probabilidades elevadas (acima de 60%) à vitória do visitado, confirmando o peso do fator casa como o preditor mais decisivo no *dataset*.
- **Empate (D):** A Figura 4b revela o maior desafio da modelação. A maioria dos classificadores concentra as suas previsões em valores baixos (entre 20% e 30%), raramente arriscando uma probabilidade elevada para o empate. O **Naive Bayes** destaca-se aqui por apresentar uma distribuição mais "achatada" e espalhada, o que explica o seu *recall* superior nesta classe: ele é o único modelo que atribui densidade de probabilidade significativa a cenários de empate onde outros modelos são conservadores.

- **Vitória Fora (A):** Na Figura 4a, as distribuições tendem a ser bimodais ou concentradas em valores intermédios. É visível que os modelos de *ensemble* (Random Forest e Gradient Boosting) são mais cautelosos, evitando atribuir probabilidades extremas de vitória ao visitante, a menos que os indicadores de ataque (`at_attack`) sejam excecionalmente superiores aos da casa.

3.3 Quantificação de Incerteza via Conformal Prediction

Para ultrapassar as limitações das probabilidades pontuais, aplicou-se o *framework* de **Conformal Prediction** utilizando a biblioteca `crepes`. O objetivo é gerar conjuntos de previsão (*prediction sets*) que garantam, com um nível de confiança $1 - \alpha$, que o resultado real está contido no conjunto.

3.3.1 Metodologia e Calibração

Utilizou-se o método *Inductive Conformal Prediction*, tirando partido do conjunto de calibração (20% dos dados) que não foi visto durante o treino. Para cada modelo, calculou-se o *non-conformity score* baseado na probabilidade da classe correta. Fixou-se um nível de significância $\alpha = 0.1$, visando uma cobertura alvo de 90%.

3.3.2 Análise de Resultados e Cobertura

Os resultados da aplicação aos diversos classificadores estão sintetizados na Tabela 2.

Modelo	Coverage	Target	Mean Set Size
Logistic Regression	89.35%	90%	2.212
Naive Bayes	89.17%	90%	2.263
Random Forest	89.44%	90%	2.328
Gradient Boosting	88.81%	90%	2.242
SVM (RBF)	89.44%	90%	2.374
Neural Network	87.56%	90%	2.383

Table 2: Resultados de Conformal Prediction para um nível de confiança de 90%.

Avaliação do Naive Bayes: O classificador **Naive Bayes** obteve uma cobertura de **89.17%**, demonstrando uma excelente aderência ao alvo teórico de 90%. Este resultado é particularmente relevante dado que, apesar de ser um modelo "sobre-confiante" nas suas probabilidades brutas, o processo de conformalização conseguiu corrigir esse viés, forçando a inclusão de mais classes no conjunto de previsão para manter a validade estatística.

Eficiência e Tamanho dos Conjuntos: A métrica *Mean Set Size* (tamanho médio do conjunto) revela a "eficiência" do modelo.

- O Naive Bayes apresentou um tamanho médio de **2.263**. Isto significa que, para garantir 90% de acerto, o modelo precisa de sugerir, em média, mais de dois desfechos possíveis (ex: $\{H, D\}$ ou $\{D, A\}$).
- Comparativamente, a **Regressão Logística** foi a mais eficiente (2.212), enquanto a **Rede Neuronal** foi a menos precisa na sua incerteza (2.383), gerando conjuntos mais amplos e, portanto, menos informativos para um apostador.

Interpretação Prática: O facto de todos os modelos apresentarem um tamanho de conjunto superior a 2.0 indica que o futebol português, sob a ótica destes atributos, contém uma incerteza intrínseca elevada. Raramente o modelo consegue garantir 90% de confiança com apenas um desfecho, validando a necessidade de abordagens que considerem múltiplos cenários para uma gestão de risco eficaz.

3.4 Avaliação de Calibração: Reliability Diagrams e Métricas de Erro

A calibração é a propriedade que garante que, se um modelo prevê uma probabilidade de 70% para um evento, este deve ocorrer aproximadamente 70% das vezes. Para avaliar esta componente nos nossos classificadores, utilizámos métricas de erro probabilístico e diagramas de fiabilidade (*Reliability Diagrams*).

3.4.1 Análise das Métricas: Brier Score e Log Loss

Os resultados obtidos antes de qualquer processo de calibração explícita encontram-se detalhados na Tabela 3.

Classificador	ROC AUC	Brier Score	Log Loss
Logistic Regression	0.6867	0.5632	0.9546
Gradient Boosting	0.6786	0.5785	0.9763
Random Forest	0.6711	0.5787	0.9814
SVM (RBF)	0.6390	0.5912	0.9950
Neural Network	0.6201	0.7742	1.6418
Naive Bayes	0.6762	0.7473	2.1232

Table 3: Métricas de desempenho probabilístico e calibração (sem ajuste).

O **Brier Score** indica que a Regressão Logística é o modelo com previsões mais próximas da realidade (0.5632). Por outro lado, o elevado **Log Loss** do Naive Bayes (2.1232) e da Rede Neuronal (1.6418) confirma que estes modelos penalizam severamente o sistema por atribuírem probabilidades muito elevadas a resultados que acabam por não se verificar.

3.4.2 Reliability Diagrams por Classe (A, D, H)

A análise visual das curvas de fiabilidade (Figura 5) permite identificar o comportamento de cada modelo face aos desfechos específicos:

- **Vitória Fora (A) e Casa (H):** Nestas classes, a maioria dos modelos (especialmente Regressão Logística e Gradient Boosting) segue a diagonal de calibração perfeita de forma aceitável. Contudo, o **Naive Bayes** situa-se sistematicamente abaixo da diagonal em probabilidades altas, o que denuncia um estado de **sobre-confiança**: o modelo acredita que o favorito ganhará com mais certeza do que a estatística real permite.
- **Empate (D):** Esta é a classe com pior calibração global. Observa-se que quase todos os modelos apresentam curvas "achatadas" ou com declives erráticos. Isto demonstra a dificuldade extrema em calibrar probabilidades para o empate, onde os modelos tendem a subestimar a ocorrência do evento quando a probabilidade prevista é intermédia.
- **Rede Neuronal:** Apresenta um comportamento oscilatório e instável em todas as classes, sugerindo que a sua arquitetura atual falha em produzir estimativas de probabilidade suaves e consistentes.




Figure 5: Reliability Diagrams comparativos para as classes Vitória Fora (A), Empate (D) e Vitória Casa (H).

Conclusão da Calibração: A Regressão Logística revela-se o modelo mais equilibrado. O Naive Bayes, apesar de ter um bom poder de discriminação (ROC AUC de 0.6762), requer obrigatoriamente um método de calibração posterior (como *Isotonic Regression*) para que as suas probabilidades possam ser usadas de forma segura na tomada de decisão baseada em utilidade.

3.4.3 Análise do Impacto dos Métodos de Calibração

Nesta secção, analisa-se a eficácia das técnicas de calibração *Sigmoid* (Platt Scaling) e *Isotonic Regression* na correção das probabilidades estimadas pelos modelos. Embora a exatidão global tenda a manter-se estável, as métricas probabilísticas revelam transformações profundas na fiabilidade do sistema.

Recuperação de Modelos Sobre-confiantes Os benefícios mais expressivos da calibração são observados nos modelos que apresentavam as piores métricas iniciais:

- **Naive Bayes:** Este modelo sofria de uma calibração deficiente (*Log Loss* de 2.1232 e *ECE* de 0.3082). A aplicação da **Calibração Isotonic** reduziu o *Log Loss* para **0.9711** e o *ECE* para uns impressionantes **0.0268**. Visualmente, as curvas que anteriormente se afastavam da diagonal de referência passam a segui-la quase perfeitamente em todas as classes (A, D, H).

- **Neural Network:** Semelhante ao Naive Bayes, a rede neuronal reduziu o seu ECE de 0.3356 para **0.0213** com o método Isotonic. Esta correção é vital, pois transforma um modelo "impreciso na sua confiança" num preditor robusto para análise de risco.

Estabilidade em Modelos Lineares e de Ensemble Para modelos que já apresentavam uma boa calibração nativa, como a **Logistic Regression** e o **Gradient Boosting**, o impacto foi marginal ou, nalguns casos, ligeiramente negativo para o *Log Loss*:

- Na **Logistic Regression**, a configuração sem calibração já apresentava o menor ECE global (0.0240). O método Isotonic degradou ligeiramente o *Log Loss* (de 0.9546 para 1.0210), sugerindo que a complexidade do ajuste não-paramétrico pode introduzir *overfitting* quando o modelo base já é linearmente calibrado.
- No **Gradient Boosting**, o método *Sigmoid* revelou-se superior ao Isotonic, reduzindo o *Log Loss* para 0.9686 e melhorando a consistência das probabilidades.

Comparação Isotonic vs. Sigmoid De uma forma geral, a **Isotonic Regression** demonstrou ser a técnica mais poderosa para corrigir desvios sistemáticos não-lineares, especialmente nas classes de difícil previsão como o **Empate (D)**. Contudo, requer um conjunto de calibração suficientemente grande para evitar o aspeto "em escada" nas previsões. A calibração *Sigmoid* mostrou-se mais conservadora e adequada para modelos onde o erro de calibração segue uma distribuição logística simples.




Figure 6: Impacto visual da calibração no Naive Bayes (esquerda) e Neural Network (direita). Observa-se a convergência das curvas para a diagonal ideal após o ajuste Isotonic (linha verde).

Em conclusão, a calibração transformou o **Naive Bayes** de um modelo estatisticamente "perigoso", devido à sobre-confiança, em um dos preditores mais fiáveis para a fase de utilidade, competindo com as métricas de erro da Regressão Logística.

3.4.4 Justificação da Escolha

A decisão de eleger a Regressão Logística como o modelo vencedor fundamenta-se nos seguintes critérios técnicos:

- **Minimização do Brier Score Global (0.5632):** Esta métrica, que mede o erro quadrático médio entre as probabilidades previstas e os resultados reais, é o indicador mais robusto de calibração. O facto de a Regressão Logística apresentar o valor mais baixo indica que as suas previsões são as que melhor refletem a frequência real dos desfechos na Liga Portuguesa.

- **Otimização do Log Loss (0.9546):** Sendo o único modelo a manter um *Log Loss* abaixo de 0.96, a Regressão Logística demonstra uma excelente gestão da incerteza, não sendo severamente penalizada por "apostas" excessivamente confiantes em resultados incorretos.
- **Parsimônia e Fiabilidade Nativa:** Ao contrário do Naive Bayes ou da Rede Neuronal, que exigiram transformações *Isotonic* pesadas para se tornarem utilizáveis, a Regressão Logística demonstrou uma calibração nativa superior (*Expected Calibration Error* de 0.0240). Isto sugere que a relação entre as variáveis contínuas do *dataset* e o desfecho do jogo é predominantemente logística, tornando o modelo mais estável para dados não vistos.

3.4.5 Ranking Final de Desempenho

A Tabela 4 resume o desempenho final de todos os modelos após a aplicação da sua melhor configuração de calibração respetiva.

Table 4: Ranking final de modelos baseado na qualidade das probabilidades (ordenado por Brier Score).

Modelo Base	Melhor Configuração	Brier Score	Log Loss	ECE
Logistic Regression	Sem Calibração	0.5632	0.9546	0.0240
Random Forest	Calibração Isotonic	0.5723	1.0810	0.0338
Gradient Boosting	Calibração Sigmoid	0.5744	0.9686	0.0340
Naive Bayes	Calibração Isotonic	0.5769	0.9711	0.0268
SVM (RBF)	Calibração Isotonic	0.5883	1.0535	0.0241
Neural Network	Calibração Isotonic	0.6108	1.0231	0.0213

Em suma, embora outros modelos possam ter atingido exatidões pontuais semelhantes, a **Regressão Logística** oferece a base probabilística mais fiável.

3.5 Otimização de Hiperparâmetros via Bayesian Optimization

Para elevar o desempenho da **Regressão Logística** para além da *baseline*, implementou-se uma estratégia de **Otimização Bayesiana** utilizando o algoritmo **BayesSearchCV**. Ao contrário do *Grid Search*, que explora o espaço de forma exaustiva e ineficiente, a otimização bayesiana utiliza processos gaussianos para construir um modelo substituto da função objetivo, explorando de forma inteligente as regiões mais promissoras do espaço de parâmetros.

3.5.1 Espaço de Procura e Regularização Elastic Net

A escolha recaiu sobre a penalização **Elastic Net**, que combina as vantagens das regularizações *L1* (Lasso) e *L2* (Ridge). Este método é particularmente útil dada a natureza do nosso *dataset*, pois permite simultaneamente a seleção de atributos e a estabilização dos coeficientes. O espaço de procura foi definido como:

- **C (Prior Log-Uniform):** Controla a força inversa da regularização, explorando desde 10^{-4} até 10^2 .
- **L1_ratio (Linear):** Define a mistura entre *L1* e *L2*, variando de 0.0 (totalmente *L2*) a 1.0 (totalmente *L1*).

3.5.2 Resultados da Otimização

Após 30 iterações com validação cruzada ($k = 5$), os parâmetros ótimos encontrados foram:

$$C \approx 0.0545, \quad l1_ratio \approx 0.7833 \quad (1)$$

A predominância de um *l1_ratio* elevado (> 0.75) sugere que o modelo beneficiou significativamente da esparsidade, indicando que algumas variáveis contínuas eram redundantes para a previsão do desfecho. O *Log Loss* em validação cruzada atingiu **0.9316**, uma melhoria consistente face aos modelos base.

3.5.3 Impacto no Desempenho Final e Calibração

A Tabela 5 detalha o desempenho do modelo otimizado no conjunto de teste independente.

Table 5: Comparação de métricas do modelo otimizado sob diferentes regimes de calibração.

Configuração	Exatidão	Log Loss	Brier Score	ECE
Sem Calibração	0.5407	0.9511	0.5617	0.0267
Calibração Sigmoid	0.5407	0.9606	0.5670	0.0475
Calibração Isotonic	0.5461	1.1398	0.5696	0.0300

Conclusões do Modelo Campeão: O processo de otimização resultou num incremento da exatidão para **54.07%** e numa redução do *Log Loss* para **0.9511**. Notavelmente, o modelo otimizado manteve a sua excelente calibração nativa, com um *Expected Calibration Error* (ECE) de apenas 0.0267 sem necessidade de ajustes *post-hoc*.

4 Teoria de Utilidade e Tomada de Decisão

Nesta fase final, o modelo deixa de ser avaliado apenas pela sua capacidade preditiva abstrata e passa a ser testado como uma ferramenta de decisão financeira. O objetivo é converter as probabilidades calibradas em apostas de valor (*Value Bets*).

4.1 Avaliação de Utilidade: O Princípio da Máxima Utilidade Esperada

Para determinar se uma aposta é lucrativa a longo prazo, comparamos as probabilidades estimadas pelo nosso modelo (P_{modelo}) com as probabilidades implícitas nas *odds* oferecidas pelas casas de apostas (P_{mercado}).

4.1.1 Cálculo do Valor Esperado (EV)

A utilidade de cada aposta é quantificada através do Valor Esperado (EV). A fórmula aplicada para cada desfecho (H, D, A) é:

$$EV = (P_{\text{modelo}} \times \text{Odd}) - 1 \quad (2)$$

Uma decisão é considerada racional e potencialmente lucrativa apenas quando $EV > 0$. Isto indica que o modelo identifica uma probabilidade de ocorrência superior àquela que as *odds* sugerem, permitindo explorar ineficiências no mercado.

4.1.2 Análise Comparativa de Calibração e Lucratividade

A Tabela 6 apresenta o impacto das diferentes técnicas de calibração no retorno financeiro acumulado sobre o conjunto de teste de 1117 jogos.

Table 6: Impacto da Calibração na Utilidade Económica (Regressão Logística)

Configuração	Brier	ECE	Value Bets	Lucro (un)	ROI (%)
Sem Calibração	0.5617	0.0267	577	-62.55	-10.84%
Calibração Sigmoid	0.5670	0.0475	636	-124.85	-19.63%
Calibração Isotonic	0.5696	0.0300	842	-127.77	-15.17%

Discussão dos Resultados: Apesar de o ROI (*Return on Investment*) ser negativo em todas as configurações, um reflexo da margem de lucro das casas de apostas e da dificuldade intrínseca de prever a Liga Portuguesa, a configuração **Sem Calibração** revelou-se a mais robusta. A calibração *Isotonic*, embora aumente o volume de apostas (842 jogos), resultou numa degradação da qualidade das *value bets*, duplicando o prejuízo acumulado. Isto confirma que a Regressão Logística otimizada já possui uma fiabilidade nativa superior, conforme demonstrado nos *Reliability Diagrams* anteriores.

4.2 Demonstração de Cenários de Decisão

Para ilustrar o funcionamento do motor de decisão, analisam-se dois cenários distintos baseados em perfis de equipas reais.

Cenário 1: Ausência de Valor (*No Bet*) Num jogo equilibrado, o modelo estimou probabilidades de $H : 0.46$, $D : 0.29$ e $A : 0.25$. Confrontando com as *odds* de mercado (2.10, 3.40, 3.50), todos os valores esperados resultaram negativos:

- $EV(Home) = (0.46 \times 2.10) - 1 = -0.033$
- $EV(Draw) = (0.29 \times 3.40) - 1 = -0.014$
- $EV(Away) = (0.25 \times 3.50) - 1 = -0.127$

Decisão: O sistema nega a aposta (*No Bet*), protegendo o capital perante a ausência de vantagem estatística.

Cenário 2: Identificação de Valor (*Value Bet*) Simulando um cenário onde a equipa da casa apresenta forma excecional (5 vitórias consecutivas e domínio histórico), o modelo atribuiu $P(H) = 0.51$. Com uma *odd* de 2.10, o cálculo revela:

- $EV(Home) = (0.51 \times 2.10) - 1 = +0.076$

Decisão: Apostar na Vitória da Casa (Home). O *EV* positivo de +7.6% indica que, se este cenário se repetisse indefinidamente, o apostador teria um lucro médio de 7.6 cêntimos por cada euro apostado.

4.3 Estratégia de Rejeição (*Reject Option*) e Gestão de Incerteza

A aplicação de modelos probabilísticos em mercados de elevada incerteza, como o das apostas desportivas, exige mecanismos de salvaguarda. Nesta secção, implementou-se uma estratégia de (**Reject Option**), permitindo ao modelo abster-se de prever resultados quando a sua confiança máxima não atinge um limiar (θ) pré-definido.

4.3.1 Análise do Trade-off: Cobertura vs. Exatidão Seletiva

A eficácia desta estratégia é visível através da relação entre a **Cobertura** (percentagem de jogos em que o modelo decide apostar) e a **Exatidão Seletiva** (taxa de acerto apenas nos jogos aceites).

- **Baseline (Sem Rejeição):** O modelo original apresenta uma exatidão de **54.07%**. Neste cenário, a cobertura é de 100%, mas o risco de erro é elevado devido à inclusão de jogos equilibrados.
- **Cenário de Alta Confiança ($\theta = 0.8$):** Ao elevarmos o limiar para 80%, a exatidão seletiva dispara para **85.71%**. Contudo, este ganho de precisão tem um custo na cobertura, que desce para **10.7%** (apenas 119 jogos aceites de um total de 1117).

4.3.2 Interpretação Visual da Confiança

As figuras integradas revelam o comportamento do classificador perante a incerteza:




Figure 7: Dinâmica de Rejeição: Evolução da cobertura e exatidão em função do limiar de confiança.

- **Curva Coverage vs Threshold:** Observa-se uma queda acentuada na cobertura a partir de $\theta > 0.4$. Isto indica que a maioria dos jogos na Liga Portuguesa apresenta um nível de incerteza onde nenhuma classe domina claramente.
- **Curva de Risco-Cobertura:** O gráfico demonstra uma correlação negativa quase linear entre cobertura e exatidão. Para obter taxas de acerto próximas de 90%, o sistema deve estar disposto a rejeitar cerca de 90% das oportunidades de mercado.




Figure 8: Distribuição de Confiança e Validação de Correctness.

Distribuição de Confiança por Correctness: A análise do histograma "*Confidence by Prediction Correctness*" é fundamental. Observa-se que as previsões **Corretas (azul)** têm uma densidade muito superior nos patamares de confiança elevada (> 0.7), enquanto as previsões **Incorretas (laranja)** se concentram na zona de incerteza (< 0.5). Isto prova que o *score* de probabilidade do modelo é um excelente estimador da realidade.

4.3.3 Conclusão da Estratégia

A implementação do `ThresholdFallbackClassifier` com $\theta = 0.8$ transforma o modelo de um predictor generalista em um especialista de precisão. Embora o lucro total absoluto possa ser menor devido ao baixo volume de apostas, o **ROI por aposta** tende a ser drasticamente superior, tornando esta estratégia ideal para uma gestão de banca conservadora onde se privilegia a segurança sobre o volume.

4.3.4 Estratégia de Deferral

Para maximizar o desempenho preditivo global, implementou-se uma lógica de **Diferimento (Deferral)**. Nesta abordagem, o sistema não se limita a rejeitar jogos incertos, mas decide dinamicamente entre utilizar a previsão do modelo ou delegar a decisão na "sabedoria do mercado", representada pelo favorito das casas de apostas (resultado com a menor *odd*). Esta técnica assume que, quando a confiança do modelo é baixa, o consenso do mercado tende a ser um previsor mais estável.

Mecânica do Sistema Híbrido A regra de decisão segue um critério de confiança limiar (θ). O sistema opera como um previsor híbrido onde:

- **Decisão do modelo:** Se $\max P(y|X) \geq \theta$, o sistema assume a previsão do modelo de Regressão Logística.
- **Diferimento:** Se $\max P(y|X) < \theta$, o sistema ignora a previsão do modelo e seleciona automaticamente o resultado apontado pelas *odds* como o mais provável.

Análise de Resultados e Trade-offs Os testes realizados com diferentes limiares revelam como a seletividade do modelo impacta a robustez do sistema. Os resultados estão sintetizados na Tabela 7.

Table 7: Desempenho do Sistema Híbrido sob diferentes limiares de confiança.

Métrica	Modelo Isolado	$\theta = 0.5$	$\theta = 0.6$	$\theta = 0.8$
Exatidão Global (Híbrido)	0.5407	0.5461	0.5461	0.5461
Exatidão Seletiva (Modelo)	-	0.7149	0.7816	0.8571
Cobertura do Modelo	100%	42.08%	28.29%	10.65%
Taxa de Diferimento	0%	57.92%	71.71%	89.35%

Discussão dos Resultados: A análise dos dados permite retirar três conclusões fundamentais sobre a sinergia entre o modelo e o mercado:

- **Superioridade do Híbrido:** Em todos os cenários testados, o sistema híbrido superou a *baseline* do modelo isolado (0.5461 vs 0.5407). Isto confirma que "deferir" para o mercado em casos de dúvida remove previsões de baixa qualidade que degradam a performance global.
- **Otimização via $\theta = 0.6$:** Este limiar apresenta-se como o "ponto de equilíbrio" ideal. Permite que o modelo ainda dite a decisão em cerca de 28% dos jogos com uma precisão muito elevada (**78.16%**), delegando os restantes jogos (mais incertos) para as *odds*. É uma estratégia que equilibra volume de jogo com segurança estatística.
- **Especialista vs. Generalista:** Com $\theta = 0.8$, o modelo torna-se um especialista, acertando **85.71%** das vezes. Contudo, a taxa de diferimento de 89.35% indica que, para manter este rigor, o sistema depende quase totalmente do mercado.

Em suma, a estratégia de *Deferral* transforma o modelo de um previsor falível num **gestor de exceções**. O sistema aprende a reconhecer os limites da sua competência e recorre aos mecanismos de consenso das casas de apostas para garantir uma base de acerto constante, intervindo apenas quando deteta uma convicção superior à média.

5 Análise Crítica e Conclusão

5.1 Discussão de Resultados: Redes Bayesianas vs. Classificadores

A comparação entre as duas grandes abordagens deste projeto revela que a escolha do modelo ideal depende do objetivo final do utilizador: a compreensão do domínio ou a performance preditiva.

Interpretabilidade e Causalidade: As Redes Bayesianas demonstraram ser ferramentas superiores para a análise qualitativa e diagnóstica. Através da engenharia de conhecimento, foi possível mapear relações causais lógicas, como o impacto do potencial ofensivo na forma recente. A capacidade de realizar inferências em qualquer direção permitiu "explicar" vitórias inesperadas através de diagnósticos sobre o estado do adversário, algo que os classificadores tradicionais não conseguem realizar de forma nativa.

Performance e Decisão: Por outro lado, para a tarefa de previsão pura e tomada de decisão financeira, os classificadores probabilísticos contínuos, especificamente a **Regressão Logística**, revelaram-se mais robustos. A Regressão Logística otimizada atingiu o melhor equilíbrio entre exatidão (54.07%) e calibração nativa (Brier Score de 0.5617). Enquanto o Naive Bayes sofreu com a sobre-confiança devida aos pressupostos de independência, a Regressão Logística manteve-se estável, provando que a relação entre as métricas de performance e o desfecho do jogo na Liga Portuguesa é predominantemente logística.

5.2 Limitações do Modelo

Apesar da sofisticação estatística, o sistema enfrenta limitações inerentes à natureza do desporto:

- **Variáveis Latentes Não Capturadas:** O modelo baseia-se em dados históricos de performance e *odds*. Fatores críticos de última hora, como lesões de jogadores-chave no aquecimento ou condições meteorológicas adversas logo no início da partida, não são capturados diretamente pelas variáveis de entrada.
- **Eficiência do Mercado:** O ROI negativo observado em todas as configurações (com um mínimo de -10.84% na melhor configuração) demonstra a elevada eficiência das casas de apostas. A margem de lucro aplicada pelas operadoras torna extremamente difícil a obtenção de lucro sistemático apenas com dados históricos, exigindo modelos ainda mais granulares para superar o custo de transação do mercado.
- **Dependência do Histórico:** A aprendizagem automática de estrutura revelou que o algoritmo tende a criar "atalhos estatísticos", utilizando as *odds* como uma variável resumo. Isto pode tornar o modelo dependente da precisão das casas de apostas, limitando a sua capacidade de encontrar valor quando o próprio mercado está enviesado.

5.3 Conclusão

Este projeto permitiu o desenvolvimento de um sistema completo de previsão probabilística, percorrendo desde a modelação causal até à implementação de estratégias de decisão de última geração.

A principal aprendizagem reside no facto de que a incerteza no futebol não pode ser eliminada, mas pode ser rigorosamente quantificada. A implementação de técnicas como *Conformal Prediction* e *Reject Option* provou ser vital, ao elevar o limiar de confiança para 80%, o modelo transformou-se de um previsor generalista num especialista capaz de acertar **85.71%** das suas previsões.

Em suma, a estratégia de **Diferimento** revelou ser o paradigma mais eficaz: utilizar o modelo como um gestor de exceções para identificar cenários de elevada convicção e delegar os jogos de alta entropia na "sabedoria do mercado".

6 Acknowledgments

No decorrer deste projeto, a inteligência artificial foi utilizada como uma ferramenta de apoio à programação, contribuindo tanto para a criação de gráficos como para a resolução de problemas relacionados com a implementação. Para além disso, a IA auxiliou na organização e estruturação do relatório.